Caminhadas aleatórias (Random Walks)

O primeiro projeto de baseia na implementação do cálculo da distribuição estacionária da cadeia de Markov a partir da matriz de transição de estados do jogo "Snakes and Ladders" (imagem1).

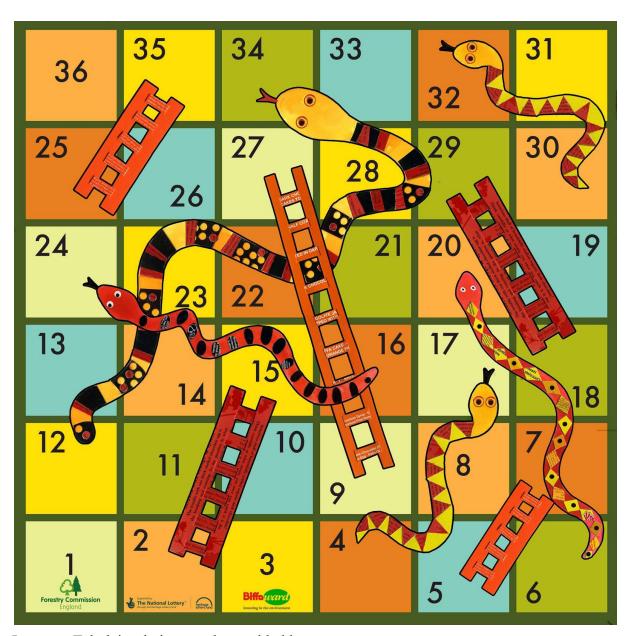


Imagem: Tabuleiro do jogo snakes and ladders.

Primeiramente foi elaborada a matriz de adjacências do tabuleiro representando o grafo do diagrama de estados presentes no jogo, a partir disso foi elaborada a matriz (delta)^-1, matriz essa que receberá em sua diagonal o valor 1/d(vi), sendo d(vi) o grau dos vértices pertencentes ao grafo.

```
15
16
17
18
19
20
21
22
23
24
25
26
27
[0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,1,1,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0],\#15
28
29
30
32
33
34
35
37
38
39
40
41
42
44
46
47
```

Imagem: Matriz de adjacência.

A matriz P, ou matriz de probabilidade é computada como sendo: P=(delta)^-1*matrizAdj, a matriz de probabilidades define o processo conhecido como Cadeia de Morkov.

```
matrizD = []
max_linhas = 36
max_colunas = 36
soma = 0
k = 0

#Computando matriz delta:

for i in range(max_linhas):
    linha = []
    for j in range(max_colunas):
        linha.append(0)
        matrizD.append(linha)
```

```
for i in range(max linhas):
  for j in range(max colunas):
    soma = soma + matrizADJ[i][j]
  matrizD[k][k] = 1/soma
  k = k+1
  soma = 0
#computando matriz P = matrizD*matrizADJ
matrizP = []
mult = 0
for i in range(max linhas):
  linha = []
  for j in range(max colunas):
    for k in range(max colunas):
       mult = mult + matrizD[i][k]*matrizADJ[k][j]
    linha.append(mult)
    mult = 0
  matrizP.append(linha)
```

Para computar o vetor de probabilidades de cada estado num tempo k, nesse exercício k =100, 'w' da cadeia de Markov Homogênea, foi utilizado o Power Method, que consiste de multiplicar a matriz de probabilidades por ela mesmo k vezes, e depois obter a partir do resultado um vetor contendo a probabilidade de se estar em cada estado em um tempo k.

```
# tempo k
for k in range(100):
    aux = []
    #multiplicação
    for i in range(36):
        aux.append(0)
        for j in range(36):
        aux[i] += v[j]*matrizP[j][i]
    v = aux
```

Resultado Obtidos

```
[0.0,
0.0,
0.0,
```

```
0.0019876139002673876,
0.0010245929380067287,
0.0010245929380067287,
0.0015844982582033495,
0.001344957181767505,
0.001510101754845458,
0.0006933106591457362,
0.00035739421106157796,
0.0024530652647714985,
0.0014487609716806375,
0.002011348331737679,
0.0017836480208753363,
0.0019562787784050436,
0.001927891325030704,
0.0010084403567855687,
0.0,
0.0,
0.0,
0.0,
0.0,
0.0,
0.0,
0.0,
0.0015568823432814804,
0.0008025561497204872,
0.0022559449592002463,
0.011278882947334912,
0.006977054299492151,
0.009410734123282851,
0.003596594392709062,
0.0018540048143700673,
0.0018540048143700673,
0.9382968462656476]
```

A matriz P Barra referente ao Page Rank foi obtida através da expressão:

```
P=(1-\alpha) P+\alpha 1/n U (Google matrix), onde \alpha=0.1 P = matriz de Probabilidades U = matriz composta unicamente por 1's
```

Para facilitar a o cálculo da google Matrix, utilizamos recursos presentes na biblioteca networkX, outro grafo sendo equivalente ao primeiro foi gerado, dessa vez com a criação do grafo utilizando da biblioteca e inserção dos vértices e arestas:

Foi criada a matriz U a calculada o Page rank através das seguintes instruções, em seguida utilizando também do Power Method, foram computados os dois resultados obtidos.

```
#matriz P_
mP_ = matrizP[i][j]*(1-alfa) + u * (alfa * (1/grafo.number_of_nodes()))

#POWER METHOD COM MATRIZ P BARRA
mP_aux = mP_
#P elevado a k
for _ in range(0, k-1):
    mP_aux = np.dot(mP_aux, mP_)

#w(100) = w(0) * P^k
wk_ = np.dot(w, mP_aux)
```

Como observado nos resultados obtidos através do Power Method utilizando-se Pagerank e Cadeia de Markov, obtivemos resultados diferentes sendo o primeiro mais preciso pois com o Pagerank não são obtidos resultados nulos na distribuição estacionária.